

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет информатики, математики и компьютерных наук

**Программа подготовки магистров по направлению
Интеллектуальный анализ данных**

Зайцев Максим Александрович

КУРСОВАЯ РАБОТА

«Контрастное обучение для автоматизации подбора промптов
языковых моделей для диалоговых систем»

Научный руководитель
доктор технических наук
Савченко А. В.

Нижний Новгород
2026

Содержание

1	Введение	4
2	Метод CRL-Prompt	5
2.1	Постановка	5
2.2	Принцип работы метода	5
2.3	Результаты CRL-Prompt	6
3	Задача настоящего исследования	7
3.1	Переход от классификации к генерации	7
4	Адаптация метода	8
5	Экспериментальная установка	10
5.1	Данные	10
5.2	Обучение и отбор	10
5.3	Программная реализация	10
5.4	Протокол оценки	10
6	Классификация эмоций	11
7	Генерация ответов	12
7.1	Качество до и после дообучения	12
7.2	Контрастные конструкции и RL	12
8	Зависимость эффекта от ёмкости модели и объёма данных	13
9	Анализ результатов	15
10	Ограничения	15
11	Заключение	16

Аннотация

Работа посвящена переносу метода контрастного обучения непрерывных промптов (CRL-Prompt) с задач классификации на генерацию диалоговых ответов с использованием decoder-only моделей Qwen2.5 размером 0.5B–3B. Исходный метод комбинирует кросс-энтропию с контрастным критерием и обучением с подкреплением при дообучении небольшого непрерывного промпта. В работе построена адаптация метода к prefix tuning, разработан протокол чистой оценки генеративной классификации и генерации ответов и проведено систематическое сравнение компонентов метода с базовым вариантом дообучения при общих начальных состояниях. Установлено, что на модели 3B ни контрастный, ни RL-компонент не дают устойчивого среднего улучшения ни в классификации, ни в генерации. В постановке, близкой к исходной, первоначально наблюдавшиеся положительные сдвиги RL-компонента и контрастного критерия не сохраняются при расширении серии независимых запусков. Для отдельных конструкций негативных примеров наблюдалась повышенная вариативность качества обучения. Полученные результаты показывают, что эффективность дополнительных критериев при переносе на авторегрессивную генерацию зависит от постановки задачи и способа формирования негативных примеров.

1. Введение

Подбор промптов стал одним из основных способов адаптации больших языковых моделей к новым задачам без изменения весов самой модели. Если дискретные текстовые инструкции подбираются вручную или поиском, то непрерывные промпты (soft prompts) настраиваются градиентными методами и требуют лишь доли процента обучаемых параметров. Для задач с дорогой разметкой такой режим особенно интересен: качество решения определяется тем, насколько хорошо сам критерий обучения использует ограниченные данные.

Стандартный критерий обучения, кросс-энтропия (максимум правдоподобия), не всегда является наилучшим прокси целевой метрики. В работе [1] предложен метод CRL-Prompt, дополняющий обучение непрерывных промптов контрастным критерием и обучением с подкреплением и показавший превосходство над чистым дообучением на ряде задач классификации. Настоящая работа исследует, переносится ли этот эффект на генеративные задачи, в частности на генерацию диалоговых ответов, при переходе к современным decoder-only моделям разных размеров.

При переносе на генерацию возникает дополнительная особенность: контрастный критерий использует представления полной последовательности с эталонным ответом, тогда как при инференсе ответ модели ещё не известен. Кроме того, влияние дополнительных критериев может зависеть от размера модели и объёма доступных данных, а для диалоговой задачи возможно несколько способов формирования отрицательных примеров.

В разделе 2 описывается исходный метод CRL-Prompt, в разделах 3–5 формулируются задача исследования, адаптация метода и экспериментальная установка. Разделы 6–8 посвящены результатам, разделы 9 и 10 обсуждению и ограничениям, раздел 11 содержит заключение.

2. Метод CRL-Prompt

2.1. Постановка

В CRL-Prompt [1] обучаются параметры непрерывного промпта при заморозенной языковой модели; параметризация соответствует схеме P-Tuning v2 [2]. Обучение проходит в две фазы. На первой фазе используется только кросс-энтропия $\mathcal{L}_{CE}$; на второй фазе минимизируется комбинированный критерий

$$\mathcal{L} = \alpha \mathcal{L}_{CE} + \beta \mathcal{L}_{ctr} + \gamma \mathcal{L}_{RL}, \quad (1)$$

где контрастный член (уравнение 3 в [1]) после L_2 -нормировки представлений имеет вид

$$\mathcal{L}_{ctr} = \log\left(1 + \sum_j \exp((\text{sim}(h^+, h_j^-) - 1)/\tau)\right), \quad (2)$$

где h^+ и h_j^- суть L_2 -нормированные представления позитивной и негативной последовательностей, агрегированные по токенам целевого ответа. RL-член (уравнение 4 в [1]) реализует REINFORCE по гауссовскому шуму параметров промпта $\theta' = \theta + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I)$:

$$\mathcal{L}_{RL} = -(r - b) \sum_i \log \mathcal{N}(\theta'_i; \theta_i, \sigma^2), \quad (3)$$

с наградой r , равной точности задачи, и базовым значением b . Негативные представления строятся возмущением (маскированием) эмбединга-слоя промпта.

2.2. Принцип работы метода

Идею CRL-Prompt можно рассматривать как дополнение обычного обучения двумя дополнительными источниками сигнала. Кросс-энтропия показывает, насколько хорошо модель предсказывает правильный ответ. Контрастный критерий добавляет положительный и отрицательный примеры и учит модель различать их представления. RL, в свою очередь, рассматривает небольшое изменение параметров промпта как пробный вариант: после такого изменения вычисляется награда, которая используется для направления последующей оптимизации. Таким образом, основная задача сохраняется, а к ней добавляются два вспомогательных сигнала.

Для контрастной части существенно, каким образом формируется отрицательный пример. В исходной работе негатив получается из того же входа за счёт возмущения представления промпта. При переносе на диалоговую задачу этот принцип сохраняется для маскирующей конструкции, а дополнительно появляются негативные ответы, различающиеся с правильным по содержанию или по форме.

2.3. Результаты CRL-Prompt

Метод проверялся на четырёх задачах классификации (AG News, TREC, SST-2, EmpatheticDialogues) с моделями RoBERTa-base (125M) и Falcon-rw-1b (1B); среднее по 10 запускам приведено в таблице 1. На всех датасетах CRL-Prompt превосходит чистое дообучение промпта (P-Tuning v2) на 0.8–4.0 п.п.; на EmpatheticDialogues (32 класса) достигнута точность 0.474 и 0.402.

Таблица 1: Результаты работы [1]: точность на тестовых выборках (их таблица 1).

Метод	AG News		TREC		SST-2		ED	
	RoB.	Fal.	RoB.	Fal.	RoB.	Fal.	RoB.	Fal.
Ручной промпт	0.470	0.450	0.500	0.390	0.730	0.790	0.272	0.203
TextGrad	0.700	0.880	0.550	0.395	0.734	0.810	0.363	0.306
APE	0.550	0.520	0.546	0.410	0.845	0.827	0.372	0.318
MixtureSoft	0.888	–	0.656	–	0.922	–	–	–
ConsPrompt	0.839	–	0.691	–	0.892	–	–	–
Prompt v1	0.927	0.929	0.922	0.672	0.898	0.948	0.437	0.385
Prompt v2	0.932	0.932	0.938	0.928	0.922	0.903	0.454	0.391
CRL-Prompt	0.940	0.946	0.960	0.962	0.940	0.943	0.474	0.402

Абляции из статьи (таблица 2) показывают положительный вклад каждого компонента: на AG News, TREC и SST-2 каждый из них в отдельности прибавляет 0.3–1.5 п.п. к чистому P-Tuning v2, а совместная конфигурация даёт 0.8–2.2 п.п. в приведённых задачах. Аналогичное сравнение компонент выполнено в настоящей работе для EmpatheticDialogues (раздел 6).

Таблица 2: Абляции.

Вариант	AG News		TREC		SST-2	
	RoB.	Fal.	RoB.	Fal.	RoB.	Fal.
Только P-Tuning v2	0.932	0.932	0.938	0.928	0.922	0.903
+ контраст ($\gamma = 0$)	0.936	0.940	0.953	0.951	0.931	0.930
+ RL ($\beta = 0$)	0.935	0.938	0.948	0.946	0.927	0.928
Полный (контраст + RL)	0.940	0.946	0.960	0.962	0.940	0.943

Из гиперпараметров работы [1], сопоставимых с настоящей адаптацией, отметим: 20 виртуальных токенов на слой; контрастную маску 10%; $\tau = 0.1$; β , подобранную перебором из $\{0.1, 0.3, 0.5\}$; $\gamma = 2 \cdot 10^{-5}$, выбранную так, чтобы RL-член составлял заметную долю суммарных потерь в начале обучения.

3. Задача настоящего исследования

В рамках настоящего исследования рассматриваются два направления расширения исходной постановки: переход к генеративным задачам диалогового характера и переход к decoder-only моделям различных размеров. Соответственно, исследование ставит три вопроса.

Вопрос 1. Как ведут себя дополнительные критерии CRL-Prompt при переходе к decoder-only модели и параметризации prefix tuning?

Вопрос 2. Даёт ли контрастная оптимизация непрерывного промпта прирост в генерации диалоговых ответов относительно чистого дообучения, и как различные конструкции негативных примеров отражаются на результате?

Вопрос 3. Как вклад компонентов метода зависит от ёмкости модели и объёма обучающих данных?

Генеративная постановка является одноходовой: эмоция используется как известное условие, а система генерирует один ответ по заданной ситуации.

3.1. Переход от классификации к генерации

Классификация и генерация используют один и тот же исходный контекст, но требуют от модели разных действий. В классификационной постановке нужно выбрать один из 32 заранее известных классов. Например:

Situation: I lost my wallet.

Emotion: anxious

Здесь множество допустимых ответов ограничено набором меток. В генеративной постановке ответ не входит во входную последовательность, и модель должна построить его самостоятельно:

Emotion: anxious

Situation: I lost my wallet.

Response:

После этого модель последовательно генерирует текст ответа. Во время обучения правильный ответ известен и используется в режиме teacher-forcing: модель получает эталонную последовательность и учится предсказывать её токены. При итоговой генерации эталонный ответ из входа удаляется, поэтому модель должна строить ответ самостоятельно.

Это различие важно для переноса контрастного критерия. Представление, которое строится по последовательности с уже известным ответом, и состояние модели в момент начала генерации не совпадают полностью. Поэтому при переносе метода возникает отдельный вопрос о том, насколько вспомогательная контрастная цель соответствует реальному режиму генерации.

4. Адаптация метода

Основные различия между постановкой в [1] и настоящей работой приведены в таблице 3. Основная идея метода сохраняется: обучаются небольшие непрерывные параметры при замороженной языковой модели, а к обычному критерию обучения добавляются вспомогательные сигналы. Отличия связаны прежде всего с архитектурой модели, параметризацией и типом целевой задачи.

Таблица 3: Сопоставление работы CRL-Prompt и настоящей адаптации.

Компонент	Исходная работа	Настоящая работа
Модель	RoBERTa-base, Falcon-rw-1b	Qwen2.5 (0.5–3B)
Параметризация	P-Tuning v2	prefix tuning с проекцией
Расписание	двухфазное	однофазное
Задача	классификация	классификация и генерация
Единица данных ED	фразы	эпизоды
Негативы	маска промпта	маска, неуместный, переставленный, путаемая метка
Награда	точность	точность, ROUGE-L
Инференс	классификация	чистая авторегрессионная генерация

(i) Постановки задач. В классификации метка предсказывается как последовательность токенов, а при оценке используется только содержательная часть метки без токена конца последовательности. В генерации целевым выходом служит первая реплика второго участника диалога. Шаблоны входа (разделителем служит перевод строки):

в классификации `Situation: {ситуация}\n Emotion:`,

в генерации `Emotion: {эмоция}\n Situation: {ситуация}\n Response:`.

Для наглядности исходный эпизод после преобразования можно представить как пример:

Emotion: proud

Situation: I finally got the job I wanted.

Response: Congratulations! That’s wonderful.

В классификационной постановке из этого примера используется соответствие «Situation → Emotion», а в генеративной постановке обучающий пример имеет структуру «Emotion + Situation → Response». Таким образом, один и тот же датасет используется для двух связанных, но различных задач.

(ii) Параметризация. Используется prefix tuning [3] (20 виртуальных токенов, репараметризация через MLP-проекцию) поверх замороженной модели Qwen2.5 [?]; для 3B это 4.81 млн обучаемых параметров (0.156%).

(iii) Организация обучения. Используется однофазное расписание, в котором контрастный критерий и RL включаются с начала обучения; такой

вариант выбран для согласования обучения с протоколом отбора лучшей эпохи.

(iv) Негативные примеры. Помимо маскирования эмбединг-слоя промпта проверяются две конструкции диалоговой семантики. Первая, *неуместный* ответ, представляет собой реплику из другого диалога: беглый ответ верного регистра, но чужого содержания. Вторая, *переставленный* ответ, получается перестановкой предложений золотого ответа (для однопредложенных ответов перестановкой слов), то есть искусственной порчей поверхности без гарантированной семантической несвязности. Для классификации дополнительно рассмотрена замена правильной метки на метку из группы близких эмоций. Формально представления агрегируются как $h^+ = \text{Pool}(H(x, y^+), M^+)$ и $h^- = \text{Pool}(H(x, y^-), M^-)$, где H означает скрытые состояния последнего слоя, $M^\pm$ маски токенов соответствующего ответа, а пулинг состоит в усреднении по маске с последующей L_2 -нормировкой. В отличие от работы [1], где негатив строится возмущением представления того же входа, здесь негативом служит представление полной альтернативной последовательности (тот же вход с чужим ответом или меткой), за исключением конструкции-маски.

(v) Награда. В классификации наградой служит точность; в генерации ROUGE-L на отложенной выборке из 600 диалогов, не входящей в обучение. Коэффициент γ калибруется автоматически по первому RL-событию так, чтобы масштаб RL-члена составлял заданную долю от кросс-энтропии, то есть переносится эвристика относительного масштаба, а не численное значение коэффициента. Во всех конфигурациях кросс-энтропия сохраняется ($\alpha = 1$): конфигурация, обозначаемая ниже CE+RL, означает добавление RL-члена к кросс-энтропии, а выводы формулируются как приращение над дообучением. Значения $\beta = 0.1$ и $\tau = 0.5$ (смягчённые относительно работы [1]) выбраны для более стабильной оптимизации в рассматриваемой постановке.

Во всех конфигурациях негативная ветвь контрастного критерия вычисляется без градиента (detached): градиент проходит только по положительной ветви.

5. Экспериментальная установка

5.1. Данные

EmpatheticDialogues [4] содержит 17 844 / 2 763 / 2 542 эпизода (обучение / валидация / тест) после дедупликации по идентификатору диалога. Единицей данных служит эпизод (диалог целиком); в работе [1] тот же датасет использовался на уровне фраз (84 170 обучающих примеров), поэтому публикуемые там точности и полученные здесь напрямую не сопоставимы. Используются подвыборки: обучение 6 000 (в развертке по объёму 250–6 000), валидация 200 (отбор эпохи), тестовая выборка из 500 примеров в основных экспериментах и полный обработанный тестовый сплит (2,542 эпизода) при дополнительной оценке; Для обучения с подкреплением использовалась отдельная выборка из 600 эпизодов, не входящих в обучающий набор. Все подвыборки формировались детерминированно как первые N эпизодов соответствующего разбиения. Распределение классов в них близко к распределению полного обучающего набора; в валидационной и тестовой выборках представлены все 32 класса.

5.2. Обучение и отбор

Обучение: 4 эпохи, батч 8, скорость обучения $5 \cdot 10^{-4}$ (cosine-расписание, прогрев 200 шагов), bf16 с fp32-параметрами промпта. Во всех конфигурациях используются одна и та же валидационная выборка и одинаковый протокол отбора лучшей эпохи по валидационной метрике (в генерации это ROUGE-L на чистом входе). Во всех сравнениях используется парный дизайн: на каждом запуске сравниваемые конфигурации стартуют с общего начального состояния промпта (в основной серии с предварительно выбранного, в развертках с общего случайного). Для основных сравнений выполнено несколько независимых запусков с общими начальными состояниями внутри каждой пары конфигураций.

5.3. Программная реализация

Исходный код, использованный для подготовки данных, проведения экспериментов и получения представленных результатов, размещён в открытом репозитории GitHub.

5.4. Протокол оценки

При итоговой оценке используется только *чистый вход*: токены целевого ответа отрезаются от конца последовательности, и модель генерирует ответ самостоятельно, без доступа к эталонному ответу или метке.

Метрики: в классификации используются генеративная точность меток (жадное декодирование не более 6 новых токенов с сопоставлением словарю 32 меток по нормализованным частичным совпадениям) и точность вербализатора (один проход, argmax по первым токенам 32 меток; первые токены всех меток уникальны). В генерации используются ROUGE-L [5] по единственному референсу, мульти-референсная версия $R(x, \hat{y}) = \max_{y \in R(x)} \text{ROUGE-L}(\hat{y}, y)$ по всем репликам собеседника (только при итоговом тестировании), BERTScore [6] (F1, модель по умолчанию для английского языка, с масштабированием относительно базовых значений) и доля уникальных n-грамм (Distinct-1/2). Декодирование во всех оценках жадное; в генерации не более 48 новых токенов. ROUGE-L во всех ролях является прокси лексического перекрытия и напрямую не измеряет релевантность, эмпатийность или связность ответа.

6. Классификация эмоций

Нулевой запуск базовой модели даёт точность 0.258, базовое дообучение промпта повышает точность до 0.62–0.63. Эти значения не следует напрямую сравнивать с результатами работы [1]: прямое сопоставление ограничено различиями в модели и единице данных (раздел 5.1). Таблица 4 сводит результаты.

Таблица 4: Классификация эмоций, Qwen2.5-3B. Среднее $\pm$ стандартное отклонение по независимым запускам. Приведены результаты на подвыборке из 500 примеров и на полном обработанном тестовом сплите (2 542 эпизода).

Конфигурация	Точность (тест 500)	Точность (полный сплит)
Нулевой запуск	0.258	–
MLE (чистое дообучение, максимум правдоподобия)	0.618 ± 0.010	0.624 ± 0.005
Контраст, маска промпта	0.628 ± 0.008	0.623 ± 0.006
Контраст, путаемая метка	0.569 ± 0.111	0.569 ± 0.118
CE+RL (REINFORCE)	0.626 ± 0.006	0.625 ± 0.007
Контраст + RL	0.619 ± 0.012	0.623 ± 0.010

На полном тестовом сплите различия относительно MLE остаются небольшими. Таким образом, на модели Qwen2.5-3B дополнительные критерии не дают устойчивого прироста качества относительно чистого дообучения промпта.

7. Генерация ответов

7.1. Качество до и после дообучения

Нулевой запуск даёт ROUGE-L 0.081; базовое дообучение промпта повышает ROUGE-L до 0.179 (тест 500) и 0.167 (тест 1000). Доля уникальных униграмм (Distinct-1) при этом снижается с 0.121 до 0.095.

7.2. Контрастные конструкции и RL

Таблица 5 сводит результаты по нескольким автоматическим метрикам. Для основных конфигураций различия относительно MLE невелики; наибольшее снижение связано с отдельным запуском переставленного ответа, у которого согласованно ниже и BERTScore. RL не показывает устойчивого улучшения ни по ROUGE-L, ни по дополнительным метрикам. Отметим, что наградой при обучении RL служит ROUGE-L по единственному референсу, а дополнительные метрики используются только при итоговой оценке.

Таблица 5: Генерация ответов, Qwen2.5-3B. Среднее $\pm$ стандартное отклонение по независимым запускам. ROUGE-L на подвыборках 500 и 1000 примеров, мульти-референсный ROUGE-L и BERTScore.

Конфигурация	R-L (500)	R-L (1000)	R-L (мульти)	BERTScore
MLE	0.179 $\pm$ 0.004	0.167 $\pm$ 0.003	0.223 $\pm$ 0.006	0.283 $\pm$ 0.003
Маска промпта	0.175 $\pm$ 0.016	0.163 $\pm$ 0.015	0.221 $\pm$ 0.016	0.291 $\pm$ 0.008
Неуместный ответ	0.178 $\pm$ 0.005	0.166 $\pm$ 0.004	0.223 $\pm$ 0.006	0.282 $\pm$ 0.003
Переставленный ответ	0.172 $\pm$ 0.018	0.160 $\pm$ 0.016	0.217 $\pm$ 0.016	0.250 $\pm$ 0.065
CE+RL (REINFORCE)	0.179 $\pm$ 0.005	0.167 $\pm$ 0.003	0.223 $\pm$ 0.005	0.281 $\pm$ 0.007
GRPO	0.177 $\pm$ 0.009	–	0.222 $\pm$ 0.006	–

Для конфигураций маски и переставленного ответа наблюдалась повышенная вариативность между запусками, включая отдельные заметно более низкие результаты. Для конструкции неуместного ответа деградировавших запусков в рассмотренной серии не наблюдалось.

В качестве дополнительного эксперимента рассмотрена токено-уровневая форма RL: групповой policy gradient (GRPO) [7], в котором действием служит порождённая последовательность, а advantage вычисляется по отклонению награды от среднего по группе сгенерированных продолжений одного контекста; RL-событие заменяет очередной шаг кросс-энтропии. Разность к MLE составляет -0.002 ± 0.004 . На отложенной выборке наблюдается снижение средней награды в ходе обучения (в среднем $0.155 \rightarrow 0.095$); в рассмотренной конфигурации это снижение не сопровождалось улучшением итогового качества. Динамика награды приведена на рисунке 1.




Рис. 1: GRPO: награда (ROUGE-L на отложенной выборке) по событиям обучения; полупрозрачные линии показывают скользящее среднее по пяти событиям. Средняя награда снижается, при этом разброс награды внутри групп сохраняется.

8. Зависимость эффекта от ёмкости модели и объёма данных

Один из результатов работы получен в развертке по ёмкости модели (0.5B–3B) и объёму обучающих данных (250–6 000) при едином протоколе с общим случайным стартом на пару (модель, запуск). Таблица 6 содержит парные разности к MLE при полной выборке.

Зависимость эффекта от ёмкости модели (EmpatheticDialogues, 6000 примеров, единый протокол)




Рис. 2: Парные разности точности к MLE при полной обучающей выборке (6 000 примеров) по трём объёмам модели; вертикальные отрезки показывают стандартные ошибки парных разностей по запускам.

С увеличением размера модели качество без дообучения возрастает (точность нулевого запуска $0.156 \rightarrow 0.184 \rightarrow 0.258$, дообученного промпта $0.541 \rightarrow 0.584 \rightarrow 0.620$), однако однозначной зависимости эффекта дополнительных критериев от размера модели в рассмотренной серии не наблюдается: наи-

Таблица 6: Данные рисунка 2: точность и парные разности к MLE при полной обучающей выборке (6 000 примеров), единый протокол.

Модель	Нулевой запуск	MLE	Маска – MLE	RL – MLE
0.5B	0.156	0.540 ± 0.005	$+0.004 \pm 0.011$	$+0.007 \pm 0.011$
1.5B	0.184	0.584 ± 0.008	-0.004 ± 0.021	-0.003 ± 0.013
3B	0.258	0.620 ± 0.007	-0.007 ± 0.019	$+0.007 \pm 0.008$

большой средний сдвиг RL-компонента получен на наименьшей модели, промежуточная точка лежит около нуля. Первоначально наблюдавшийся на наименьшей модели прирост RL не сохраняется при расширении серии независимых запусков: в объединённой серии устойчивого улучшения не наблюдается, а величина эффекта различается при разных начальных состояниях промпта.

При малом объёме обучающих данных (250 примеров) первоначально наблюдавшийся прирост контрастной конфигурации также не сохраняется при расширении серии независимых запусков; аналогичного устойчивого улучшения для RL-компонента не наблюдается. Полные кривые обучения по объёму данных приведены на рисунке 3 и в таблице 7.

Точность по объёму обучающих данных (сглаживание: 3–10 сидов на точку)




Рис. 3: Точность классификации по объёму обучающих данных (лог-шкала); пунктир показывает уровень нулевого запуска, отрезки показывают стандартные ошибки по запускам.

При фиксированном четырёхэпохном расписании размер обучающей выборки определяет и число шагов оптимизатора, поэтому приведённые кривые описывают зависимость качества от размера выборки при данном расписании, а не чистый эффект количества данных как такового.

Таблица 7: Данные рисунка 3: точность MLE и контрастных конфигураций по объёму обучающей выборки.

Модель	Примеров	MLE	Маска	RL
0.5B	250	0.385 ± 0.014	0.390 ± 0.016	0.389 ± 0.012
0.5B	1000	0.513 ± 0.022	0.501 ± 0.039	0.510 ± 0.018
0.5B	6000	0.541 ± 0.005	0.544 ± 0.013	0.547 ± 0.015
3B	250	0.543 ± 0.006	0.537 ± 0.008	0.549 ± 0.012
3B	500	0.567 ± 0.010	0.573 ± 0.022	0.579 ± 0.011
3B	1000	0.586 ± 0.016	0.583 ± 0.015	0.577 ± 0.008
3B	6000	0.620 ± 0.007	0.613 ± 0.024	0.627 ± 0.006

9. Анализ результатов

Полученные результаты показывают, что эффект дополнительных критериев CRL-Prompt зависит от постановки задачи, способа построения негативных примеров и конфигурации модели. В рассмотренных сериях устойчивого улучшения относительно чистого дообучения не наблюдалось, а величина наблюдаемых эффектов зависит от начального состояния промпта.

Одним из возможных объяснений результата в генеративной постановке является рассогласование между режимом формирования представлений при обучении и состоянием модели в момент генерации: контрастная ветвь использует представления последовательности, содержащей эталонный ответ, тогда как при генерации этот ответ отсутствует.

Способ построения негативных примеров влияет на наблюдаемое поведение: для отдельных конструкций наблюдалась повышенная вариативность результатов, включая отдельные заметно деградировавшие траектории обучения, тогда как конструкции без лексического пересечения с позитивом вели себя стабильнее. Для RL ни одна из рассмотренных форм улучшения генерации не дала; в конфигурации GRPO снижение обучающей награды не сопровождалось улучшением итогового качества. Одним из возможных объяснений может быть несогласование используемой награды с итоговой метрикой генерации; дополнительные факторы требуют отдельного исследования.

Дальнейшая работа может рассмотреть контрастные цели, непосредственно основанные на сгенерированных моделью кандидатах, а также сопоставление различных конструкций негативных примеров при большем числе независимых запусков.

10. Ограничения

Полученные результаты относятся к одному датасету EmpatheticDialogues и одному семейству decoder-only моделей Qwen2.5. Генеративная постановка является одноходовой и использует известную эмоцию как условие. Качество

ответов оценивается автоматическими метриками, поэтому выводы характеризуют прежде всего сходство с референсными ответами и не заменяют человеческую оценку диалогового качества.

11. Заключение

В работе исследован перенос контрастной оптимизации непрерывных промптов, задаваемой методом CRL-Prompt, с классификации на генерацию диалоговых ответов при переходе к decoder-only моделям Qwen2.5. Построена адаптация метода к параметризации prefix tuning, предложены конструкции негативных примеров из диалоговой семантики и протокол чистой оценки генерации.

В рассмотренной постановке прямой перенос не приводит к устойчивому улучшению относительно базового дообучения промпта ни в классификации, ни в генерации: первоначально наблюдавшиеся положительные сдвиги отдельных компонентов не сохранялись при расширении серии независимых запусков. Для отдельных конструкций негативных примеров наблюдалась повышенная вариативность качества обучения.

Полученные результаты показывают, что эффективность контрастного обучения в задаче авторегрессивной генерации зависит от выбора вспомогательных критериев и способа формирования отрицательных примеров

Литература

1. Lapokin, D., Savchenko, A. CRL-Prompt: Contrastive Reinforcement Learning for Soft Prompt Tuning // Proc. ACL SRW. 2026.
2. Liu, X., et al. P-Tuning v2: Prompt Tuning Can Be Comparable to Fine-tuning Universally Across Scales and Tasks // Proc. ACL. 2022.
3. Li, X.L., Liang, P. Prefix-Tuning: Optimizing Continuous Prompts for Generation // Proc. ACL. 2021.
4. Rashkin, H., Smith, E.M., Li, M., Boureau, Y.-L., Taylor, J. Towards Empathetic Open-Domain Conversation Models: A New Benchmark and Dataset // Proc. ACL. 2019.
5. Lin, C.-Y. ROUGE: A Package for Automatic Evaluation of Summaries // Text Summarization Branches Out. 2004.
6. Zhang, T., et al. BERTScore: Evaluating Text Generation with BERT // Proc. ICLR. 2020.
7. Shao, Z., et al. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models // arXiv:2402.03300. 2024.